Guía de práctica: Recuperatorio del 1er parcial

Aprendizaje Automático — 2C 2026

Teoría de la decisión · Cuadrados mínimos · SVD · Ridge · Lasso · Papers (Breiman, Donoho, Efron)

Cómo usar esta guía. Los ejercicios están en orden: cada bloque arranca con cuentas chicas y termina en un ejercicio del nivel del parcial. Conviene hacerlos en orden.

- Dificultad: ★ directo, ★★ desarrollo, ★★★ nivel parcial o más.
- A la derecha figura la fuente: *Parcial 1* (el del 25/9), *Cátedra* (notebooks o Guía 0), ESL, ISLR, Bishop, MML, o *Propio*.
- La Parte II es para la compu y está en el notebook `Guia_A_computadora.ipynb`.
- Al final están los **resultados** (sin desarrollo), para chequear.

Notación de la materia: $\mathbf{X}$ es $N \times (p+1)$ con columna de unos, $\mathbf{x}_j$ es la columna j, $\hat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$. Cuando se dice "estandarizados", el desvío se calcula dividiendo por N, así que $\mathbf{x}_j^T\mathbf{x}_j = N$.

Parte I — A mano

Bloque 1. Álgebra y SVD

Ejercicio 1 ★

Propio

Columnas ortonormales no es lo mismo que matriz ortogonal. Sea

$$\mathbf{U} = \begin{pmatrix} 1/\sqrt{2} & 0 \\ 1/\sqrt{2} & 0 \\ 0 & 1 \end{pmatrix}.$$

a) Calculá $\mathbf{U}^T\mathbf{U}$ y $\mathbf{U}\mathbf{U}^T$. ¿Cuál es la identidad?

b) Verificá que $\mathbf{P} = \mathbf{U}\mathbf{U}^T$ es simétrica e idempotente ($\mathbf{P}^2 = \mathbf{P}$). Calculá $\mathrm{tr}(\mathbf{P})$.

c) Calculá $\mathbf{P}v$ para $v = (1, 3, 2)^T$ e interpretalo geométricamente.

d) Si $\mathbf{X} = \mathbf{U}\mathbf{D}\mathbf{V}^T$ es la SVD reducida de $\mathbf{X}$ ($N \times p$, rango p), mostrá que la matriz sombrero $\mathbf{H} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$ es igual a $\mathbf{U}\mathbf{U}^T$. ¿Cuándo vale $\mathbf{U}\mathbf{U}^T = \mathbf{I}$?

Ejercicio 2 ★★

Propio · estilo Parcial 1, Ej. 1 · MML 4.8

Sea $\mathbf{X} = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$.

a) Calculá $\mathbf{X}^T\mathbf{X}$, sus autovalores y autovectores. Deducí los valores singulares de $\mathbf{X}$ y la matriz $\mathbf{V}$. Usá $v_1 = (1,1)^T/\sqrt{2}$ y $v_2 = (1,-1)^T/\sqrt{2}$.

b) Obtené $\mathbf{U}$ con $u_j = \mathbf{X}v_j/d_j$. $\mathbf{X}$ es simétrica: ¿por qué igual $\mathbf{U} \neq \mathbf{V}$?

c) Con esas matrices y $\mathbf{D} = \mathrm{diag}(3, 1)$, indicá V o F. Si es F, calculá el producto.

(i) $\mathbf{U}^T\mathbf{U} = \mathbf{I}$ (ii) $\mathbf{V}\mathbf{V}^T = \mathbf{I}$ (iii) $\mathbf{U}\mathbf{D}\mathbf{V}^T = \mathbf{X}$ (iv) $\mathbf{V}\mathbf{D}\mathbf{U}^T = \mathbf{X}$
(v) $\mathbf{X}\mathbf{V} = \mathbf{U}\mathbf{D}$ (vi) $\mathbf{D}\mathbf{V}^T = \mathbf{X}$ (vii) $\mathbf{X}^T\mathbf{X} = \mathbf{V}\mathbf{D}^2\mathbf{V}^T$ (viii) $\mathbf{V}^T\mathbf{D}\mathbf{U} = \mathbf{X}$

d) Para $\mathbf{A} = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{pmatrix}$, calculá los valores singulares usando la matriz de 2×2 que corresponda. ¿Por qué conviene $\mathbf{A}\mathbf{A}^T$ y no $\mathbf{A}^T\mathbf{A}$?

Revisá el orden de los valores singulares: en el parcial, $\mathbf{D}$ tenía que ser coherente con las columnas de $\mathbf{U}$ y $\mathbf{V}$ dadas, no necesariamente en orden decreciente.

Bloque 2. Teoría de la decisión

Ejercicio 3 ★

Propio

Sea $X \in \{0, 1\}$ con $P(X = 0) = P(X = 1) = 1/2$, y

$Y \mid X = 0$	0	1	2
P	0,2	0,5	0,3

$Y \mid X = 1$	0	1	10
P	0,3	0,4	0,3

a) Calculá el predictor óptimo $f(x)$ para $x = 0, 1$ bajo pérdida cuadrática, absoluta y 0-1.

b) Calculá el EPE de cada predictor óptimo con su propia pérdida.

c) Calculá el EPE con pérdida *absoluta* del predictor óptimo para la *cuadrática*. Comparalo con (b).

d) ¿En qué celda difieren más media y mediana y por qué? En una línea: ¿cuándo preferirías la pérdida absoluta?

Ejercicio 4 ★★

Parcial 1, Ej. 2 · Bishop 1.27

Bajo la pérdida cuadrática, el predictor que minimiza el EPE es $f(x) = \mathbb{E}[Y \mid X = x]$. Ahora usamos $L(Y, f(X)) = |Y - f(X)|$.

a) Escribí el EPE como $\mathbb{E}_X\big[\mathbb{E}_{Y|X}(\cdot \mid X)\big]$ y explicá en una línea por qué se puede minimizar punto a punto.

b) Para x fijo, planteá $\min_c \mathbb{E}\big[|Y - c| \mid X = x\big]$ como integral, partila en $y < c$ e $y > c$, derivá respecto de c y obtené la condición de óptimo.

c) ¿Qué estadístico de $p(Y \mid X = x)$ es la predicción óptima?

d) Generalizá: con la pérdida asimétrica $L_\tau(y, c) = \tau\,(y - c)$ si $y \geq c$ y $(1 - \tau)(c - y)$ si $y < c$ $(0 < \tau < 1)$, ¿qué estadístico es óptimo? ¿Para qué sirve en la práctica?

e) En una línea: ¿en qué situación preferís la pérdida absoluta a la cuadrática?

Ejercicio 5 ★

Propio · Bishop 1.5.2

Teoría de la decisión con matriz de pérdida $L(k, \ell)$: el costo de clasificar como ℓ algo que es de clase k.

a) Dos clases: *enfermo* y *sano*, con $q = P(\text{enfermo} \mid x)$. Clasificar a un enfermo como sano cuesta 10; a un sano como enfermo, 1. Encontrá el umbral sobre q que minimiza el riesgo. Compará con la pérdida 0-1.

b) Tres clases con posterior $p(\cdot \mid x) = (0{,}5;\ 0{,}3;\ 0{,}2)$ y $\mathbf{L} = \begin{pmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 4 & 4 & 0 \end{pmatrix}$ (filas: clase verdadera; columnas: predicha). Calculá el riesgo esperado de predecir cada clase. ¿Qué predecís? ¿Y con pérdida 0-1?

Bloque 3. Cuadrados mínimos

Ejercicio 6 ★

Propio · Guía 0, Ej. 5

Datos: $x = (0, 1, 2, 3)$, $y = (1, 3, 2, 6)$. Modelo $f(x) = \beta_0 + \beta_1 x$.

a) Armá $\mathbf{X}$ (con columna de unos) y calculá $\mathbf{X}^T\mathbf{X}$ y $\mathbf{X}^T\mathbf{y}$.

b) Resolvé las ecuaciones normales y obtené $\hat{\beta}$.

c) Calculá $\hat{\mathbf{y}}$ y el vector de residuos $\mathbf{e}$. Verificá que $\mathbf{X}^T\mathbf{e} = 0$ y explicá qué dicen esas dos ecuaciones.

d) Calculá la diagonal de $\mathbf{H}$ y su traza. Calculá el RSS.

Ejercicio 7 ★★

Cátedra

Descenso por gradiente sobre $\text{RSS}(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2$.

a) Usando $\partial(a^T\beta)/\partial\beta = a$ y $\partial(\beta^T\mathbf{A}\beta)/\partial\beta = 2\mathbf{A}\beta$ ($\mathbf{A}$ simétrica), calculá el gradiente y el hessiano. ¿Por qué el RSS es convexo?

b) Escribí la actualización $\beta^{(t+1)} = \beta^{(t)} - \eta\nabla\text{RSS}$.

c) Con los datos del ejercicio anterior, $\beta^{(0)} = 0$ y $\eta = 0{,}02$, hacé dos iteraciones.

d) Llamando $e^{(t)} = \beta^{(t)} - \hat{\beta}$, mostrá que $e^{(t+1)} = (\mathbf{I} - 2\eta\mathbf{X}^T\mathbf{X})\, e^{(t)}$. Deducí que converge si y solo si $\eta < 1/\lambda_{\max}(\mathbf{X}^T\mathbf{X})$. Calculá esa cota para estos datos.

e) ¿Qué esperás que pase con $\eta = 0{,}05$? ¿Y con $\eta = 0{,}07$?

Ejercicio 8 ★★

Cátedra · ESL 3.2

Supuestos: $\mathbf{X}$ fija y $\mathbf{y} = \mathbf{X}\beta + \varepsilon$, con $\varepsilon \sim N(0, \sigma^2\mathbf{I})$.

a) Mostrá que $\mathbb{E}[\hat{\beta}] = \beta$ y $\text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}^T\mathbf{X})^{-1}$.

b) Para los datos del Ejercicio 6, escribí $\text{Var}(\hat{\beta}_0)$, $\text{Var}(\hat{\beta}_1)$ y $\text{Cov}(\hat{\beta}_0, \hat{\beta}_1)$ en función de σ^2.

c) Escribí la log-verosimilitud y mostrá que maximizarla en β da el mismo $\hat{\beta}$ que cuadrados mínimos. ¿Qué estimador de σ^2 da máxima verosimilitud?

d) Usando $\mathbb{E}[\text{RSS}] = \sigma^2\,\text{tr}(\mathbf{I} - \mathbf{H})$, mostrá que $\mathbb{E}[\text{RSS}] = \sigma^2(N - p - 1)$. ¿El estimador de MV de σ^2 es insesgado? Calculá el insesgado para los datos del Ejercicio 6.

e) Enunciá Gauss-Markov. ¿Dice algo sobre estimadores *sesgados*?

Ejercicio 9 ★★

Propio · preparación Parcial 1, Ej. 5

Dos predictores estandarizados $\mathbf{x}_1, \mathbf{x}_2$ (desvío dividiendo por N), con correlación $\rho = \frac{1}{N}\sum_i x_{i1}x_{i2}$, y target centrado. Modelo $f = \beta_0 + \beta_1\mathbf{x}_1 + \beta_2\mathbf{x}_2$.

a) Calculá $\mathbf{X}^T\mathbf{X}$ (es 3×3; la columna de unos va primero).

b) Invertí el bloque de 2×2 y escribí $\hat{\beta}_0$, $\hat{\beta}_1$, $\hat{\beta}_2$ en función de $\sum_i x_{i1}y_i$, $\sum_i x_{i2}y_i$, ρ y N. ¿Cuánto vale $\bar{y}$? ¿Es lo mismo escribir $\hat{\beta}_0 = 0$ que $\hat{\beta}_0 = \bar{y}$?

c) Mostrá que $\text{Var}(\hat{\beta}_1) = \dfrac{\sigma^2}{N(1-\rho^2)}$. Evaluá el factor $1/(1-\rho^2)$ para $\rho = 0{,}9$ y $\rho = 0{,}99$.

d) Calculá los autovalores del bloque $\frac{1}{N}\begin{pmatrix} N & N\rho \\ N\rho & N \end{pmatrix}$ y relacionalo con la Guía 0, Ej. 12.

e) Si sacás $\mathbf{x}_2$ del modelo, ¿cuánto vale el nuevo coeficiente de $\mathbf{x}_1$? Escribilo en función de $\hat{\beta}_1$, $\hat{\beta}_2$ y ρ.

Ejercicio 10 ★★

Propio

Predictores idénticos sin regularizar. Sean $x = (1, -1, 2, -2)$, $y = (2, -1, 3, -4)$ (ambos centrados, modelo sin intercepto) y $\mathbf{X} = [\,\mathbf{x}\;\;\mathbf{x}\,]$.

a) Mostrá que $\mathbf{X}^T\mathbf{X}$ es singular. ¿Qué rango tiene $\mathbf{X}$?

b) Mostrá que el RSS depende de β_1, β_2 solo a través de $\beta_1 + \beta_2$. ¿Cuánto debe valer esa suma en el óptimo?

c) Calculá la SVD de $\mathbf{X}$ (un único valor singular no nulo) y la solución $\hat{\beta} = \mathbf{V}\mathbf{D}^{+}\mathbf{U}^T\mathbf{y}$ con la pseudoinversa. ¿Qué tiene de especial entre todas las soluciones?

Bloque 4. SVD, Lagrange y Ridge

Ejercicio 11 ★★

Cátedra · ESL 3.4.1

Sea $\mathbf{X} = \mathbf{U}\mathbf{D}\mathbf{V}^T$ (centrada, sin columna de unos, rango completo).

a) Mostrá que $\hat{\beta}^{ols} = \mathbf{V}\mathbf{D}^{-1}\mathbf{U}^T\mathbf{y}$ y que $\hat{\mathbf{y}} = \sum_j u_j\,(u_j^T\mathbf{y})$.

b) Mostrá que $\hat{\mathbf{y}}^{ridge} = \sum_j u_j \dfrac{d_j^2}{d_j^2 + \lambda}\,(u_j^T\mathbf{y})$.

c) Los grados de libertad efectivos son $\mathrm{df}(\lambda) = \mathrm{tr}\left(\mathbf{X}(\mathbf{X}^T\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}^T\right) = \sum_j \frac{d_j^2}{d_j^2+\lambda}$. Con $d = (4;\ 2;\ 0{,}5)$, completá la tabla con los factores de encogimiento y el df para $\lambda = 0, 1, 4, 16$.

d) ¿Qué dirección encoge más rápido Ridge? Relacionalo con la Guía 0, Ej. 12.

Ejercicio 12 ★

Cátedra · intermezzo Lagrange

a) Con multiplicadores de Lagrange, minimizá $\beta_1^2 + \beta_2^2$ sujeto a $\beta_1 + \beta_2 = c$.

b) Minimizá $|\beta_1| + |\beta_2|$ sujeto a $\beta_1 + \beta_2 = c$ ($c > 0$). Describí el conjunto de soluciones y dibujalo.

c) Dibujá en el plano (β_1, β_2) las curvas de nivel del RSS (elipses) y las regiones $\beta_1^2 + \beta_2^2 \le t$ y $|\beta_1| + |\beta_2| \le t$. Explicá por qué Lasso puede dar coeficientes exactamente cero y Ridge no.

Ejercicio 13 ★

ISLR 6.6 (adaptado)

Ridge con un solo predictor centrado, sin intercepto: $\min_\beta\ \|\mathbf{y} - \beta\mathbf{x}\|^2 + \lambda\beta^2$.

a) Derivá $\hat{\beta}^{ridge}$ en función de $\mathbf{x}^T\mathbf{y}$, $\mathbf{x}^T\mathbf{x}$ y λ.

b) Con los datos del Ejercicio 10 (una sola copia de x), calculalo para $\lambda = 0, 5, 10$.

c) ¿Qué pasa cuando $\lambda \to \infty$? ¿Qué fracción de $\hat{\beta}^{ols}$ queda?

Ejercicio 14 ★★

ESL 3.29

Ridge reparte el peso entre copias de una variable.

a) Con una sola variable, Ridge da $a = \mathbf{x}^T\mathbf{y}/(\mathbf{x}^T\mathbf{x} + \lambda)$. Agregás una copia exacta $\mathbf{x}^* = \mathbf{x}$. Mostrá que los dos coeficientes son iguales (pista: simetría y convexidad estricta) y calculá su valor.

b) Con los datos del Ejercicio 10 y $\lambda = 5$, calculá los dos coeficientes y su suma. Compará con el Ejercicio 13. ¿Por qué la suma cambia?

c) Generalizá a m copias.

Ejercicio 15 ★★

Parcial 1, Ej. 3 · ESL 3.12 y 3.30

Datos aumentados. $\mathbf{X}$ está centrada (sin columna de unos) e $\mathbf{y}$ centrado.

a) Sean $\tilde{\mathbf{X}} = \begin{pmatrix} \mathbf{X} \\ a\,\mathbf{I}_p \end{pmatrix}$ y $\tilde{\mathbf{y}} = \begin{pmatrix} \mathbf{y} \\ b\,\mathbf{1}_p \end{pmatrix}$. Desarrollá $\|\tilde{\mathbf{y}} - \tilde{\mathbf{X}}\beta\|^2$. ¿Qué valores de a y b dan exactamente la función de costo de Ridge? Elegí entre:
☐ $a = \sqrt{\lambda},\ b = 0$ ☐ $a = \lambda,\ b = 0$ ☐ $a = \lambda,\ b = 1$ ☐ $a = 1,\ b = \lambda$.

b) ¿Qué aumentación da la penalidad $\lambda\|\beta - \beta^0\|^2$, que encoge hacia un vector β^0 en lugar de hacia 0?

c) ¿Se puede obtener Lasso con una aumentación de este tipo? Respondé en una oración.

d) (ESL 3.30) Mostrá que Elastic Net, $\|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda_2\|\beta\|_2^2 + \lambda_1\|\beta\|_1$, es un Lasso sobre datos aumentados. Indicá la aumentación.

Ejercicio 16 ★★

Propio · ISLR 6.4

¿Por qué conviene sesgar? Predictores estandarizados y ortogonales ($\mathbf{X}^T\mathbf{X} = N\mathbf{I}$). Entonces $\hat{\beta}_j^{ols}$ tiene media β_j y varianza σ^2/N, y Ridge da $\hat{\beta}_j^{ridge} = s\,\hat{\beta}_j^{ols}$, con $s = N/(N+\lambda)$.

a) Escribí sesgo, varianza y ECM de $\hat{\beta}_j^{ridge}$ en función de s.

b) Encontrá el λ^* que minimiza el ECM. ¿Es siempre $\lambda^* > 0$? ¿Se puede calcular en la práctica?

c) ¿Por qué esto no contradice Gauss-Markov?

d) (ISLR 6.4) Cuando λ crece desde 0, ¿qué pasa con: el RSS de entrenamiento, el RSS de test, la varianza, el sesgo^2 y el error irreducible? Elegí entre: crece siempre, decrece siempre, forma de U, U invertida, constante.

Ejercicio 17 ★★

Cátedra

Soft-thresholding. Sea $h(\beta) = \frac{1}{2}\beta^2 - a\beta + \lambda|\beta|$, con $\lambda > 0$.

a) Minimizá h separando los casos $\beta > 0$, $\beta < 0$ y $\beta = 0$. Mostrá que $\hat{\beta} = S(a,\lambda) = \text{sign}(a)\,(|a| - \lambda)_+$.

b) Calculá $S(3,1)$, $S(-0{,}5;\ 1)$ y $S(-2;\ 0{,}5)$.

c) Repetí con $\frac{1}{2}\beta^2 - a\beta + \frac{\lambda}{2}\beta^2$ (versión Ridge). Graficá las dos soluciones en función de a en un mismo dibujo.

d) En *coordinate descent*, ¿qué es a cuando se actualiza β_j?

Ejercicio 18 ★★★

Parcial 1, Ej. 4 · ISLR 6.5

Coordinate descent con predictores idénticos. Sean $N = 4$, $x = (1,1,-1,-1)$ (estandarizado), $y = (3,1,-1,-3)$ (centrado) y tres predictores idénticos $\mathbf{x}_1 = \mathbf{x}_2 = \mathbf{x}_3 = \mathbf{x}$. Costo:

$$R(\beta) = \frac{1}{2N}\|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda\sum_{j=1}^{3}|\beta_j|, \qquad \lambda = 0{,}5.$$

a) Calculá $\frac{1}{N}\mathbf{x}^T\mathbf{y}$.

b) Barrido cíclico en orden $1,2,3$ desde $\beta = 0$: hacé dos barridos completos, actualizando cada coordenada con $S\big(\frac{1}{N}\mathbf{x}_j^T r^{(j)}, \lambda\big)$, donde $r^{(j)}$ es el residuo parcial.

c) Repetí en orden $3,2,1$. Repetí en orden $1,2,3$ pero arrancando de $\beta = (0{,}5;\ 0{,}5;\ 0{,}5)$.

d) Evaluá R en los tres resultados. Describí el conjunto de todas las soluciones de Lasso.

e) Con el mismo costo, pero con $\frac{\lambda}{2}\|\beta\|_2^2$ como penalidad (Ridge), ¿cuánto vale cada coeficiente?

f) Respondé la pregunta del parcial: con barrido cíclico en orden $1, 2, 3$ e inicialización en 0, ¿cómo son los pesos al final del entrenamiento? Justificá con lo anterior.

Ejercicio 19 ★★★

Parcial 1, Ej. 6 (integrador)

Cosas maravillosas ocurren cuando los predictores son ortogonales. Los predictores están estandarizados y son ortogonales entre sí.

a) Completá: $\mathbf{X} = [\ \cdots\ ]$ (no te olvides de la columna de unos), $\mathbf{x}_j^T \mathbf{x}_j = ?$, $\mathbf{x}_j^T \mathbf{x}_k = ?$ $(j \neq k)$, $\mathbf{1}^T \mathbf{x}_j = ?$.

b) Calculá $\mathbf{X}^T\mathbf{X}$, $(\mathbf{X}^T\mathbf{X})^{-1}$, $(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$, $\hat{\beta}$, $\hat{\beta}_0$ y $\hat{\beta}_j$.

c) En una línea, interpretá $\hat{\beta}_j$. (Pista: compará con una regresión simple sobre $\mathbf{x}_j$.)

d) ¿Qué pasa con $\hat{\beta}_j$ $(j \neq 0, k)$ si se elimina x_k? Compará con el ítem (e) del Ejercicio 9.

e) Ridge con costo $\|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \sum_{j \geq 1} \beta_j^2$: escribí $\hat{\beta}_j^{ridge}$ en función de $\hat{\beta}_j$.

f) Lasso con costo $\frac{1}{2N}\|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \sum_{j \geq 1} |\beta_j|$: escribí $\hat{\beta}_j^{lasso}$ en función de $\hat{\beta}_j$.

g) Números: $x_1 = (1, 1, -1, -1)$, $x_2 = (1, -1, 1, -1)$, $y = (5, 3, 1, -1)$. Calculá $\hat{\beta}$ (MCO), Ridge con $\lambda = 4$ y Lasso con $\lambda = 1{,}5$.

En el parcial, los errores de este ejercicio salieron de no reemplazar $\mathbf{x}_j^T \mathbf{x}_j$ por N (los predictores están estandarizados). Todo lo demás sale de ahí.

Ejercicio 20 ★★

ESL 3.6 · ISLR 6.7

Conexión bayesiana. Sea $\mathbf{y} \mid \beta \sim N(\mathbf{X}\beta, \sigma^2\mathbf{I})$.

a) Con prior $\beta \sim N(0, \tau\mathbf{I})$, mostrá que la moda (y la media) de la posterior es el estimador Ridge. ¿Cuánto vale λ en función de τ y σ^2?

b) Con prior Laplace $p(\beta_j) = \frac{1}{2b} e^{-|\beta_j|/b}$ independientes, mostrá que la moda de la posterior es Lasso para el costo $\|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \sum_j |\beta_j|$. ¿Cuánto vale λ?

c) ¿La *media* de la posterior con prior Laplace tiene coeficientes exactamente cero? ¿Por qué?

Bloque 5. Papers

Ejercicio 21 ★

Parcial 1, Ej. 7 (afirmaciones nuevas)

Asigná cada afirmación a **Breiman** (2001), **Donoho** (2017) o **Efron** (2020).

Afirmación	Autor
1. Para un mismo conjunto de datos suele haber muchos modelos distintos, con variables distintas, que alcanzan casi el mismo error. Sacar conclusiones sobre el mecanismo de la naturaleza a partir de uno solo de ellos es riesgoso.	
2. Agregar muchas variables, incluso construidas a partir de las originales, puede mejorar la predicción: la alta dimensionalidad puede ser una bendición y no solo una maldición.	
3. El modelo de regresión tradicional puede pensarse como "superficie más ruido". Los algoritmos de predicción pura no necesitan estimar esa superficie para predecir bien.	
4. Combinar una multitud de predictores débiles funciona muy bien para predecir, pero esa estrategia no sirve para la atribución, que busca predictores individuales fuertes.	
5. Hace más de cincuenta años ya se planteaba que el análisis de datos debía ser una ciencia propia, más amplia que la estadística matemática.	
6. Una de las divisiones de la ciencia de datos debería estudiar empíricamente a la propia ciencia de datos: comparar flujos de trabajo y métodos sobre muchos conjuntos de datos.	
7. Si la relación entre predictores y respuesta cambia con el tiempo, una regla de predicción entrenada con datos viejos puede fallar con datos nuevos aunque haya tenido bajo error en un test elegido al azar.	
8. En la comunidad estadística, la gran mayoría trabaja asumiendo un modelo estocástico para los datos y solo una minoría usa modelos algorítmicos que tratan el mecanismo como una caja negra.	

Parte II — En la computadora

Notebook `Guia_A_computadora.ipynb`. Son para ver conceptos, no para programar mucho: cada uno tiene una celda de preparación y el resto lo completás vos.

Ejercicio 22 ★★

Propio · Guía 0, Ej. 12

Multicolinealidad. Simulá $x_2 = \rho\, x_1 + \sqrt{1-\rho^2}\, z$ con $\rho \in \{0;\ 0{,}5;\ 0{,}9;\ 0{,}99\}$. Para cada ρ, repetí 500 veces: generá $\mathbf{y}$, ajustá MCO y guardá $\hat{\beta}_1$. Compará la varianza empírica de $\hat{\beta}_1$ con $\sigma^2/(N(1-\rho^2))$ (Ejercicio 9). Calculá el número de condición de $\mathbf{X}^T\mathbf{X}$. Resolvé con `inv`, `solve`, `lstsq` y con SVD. ¿Cuándo empiezan a diferir?

Ejercicio 23 ★★

Cátedra · ESL Fig. 3.8

Ridge vía SVD en *Prostate*. Con los predictores estandarizados del conjunto de entrenamiento, implementá Ridge con la fórmula del Ejercicio 11. Graficá los coeficientes en función de $\mathrm{df}(\lambda)$. Verificá contra `sklearn.linear_model.Ridge(alpha=`λ`)`. Graficá también los factores $d_j^2/(d_j^2+\lambda)$ para cada componente.

Ejercicio 24 ★★★

Cátedra · Parcial 1, Ej. 4

Coordinate descent. Implementá Lasso por coordinate descent con soft-thresholding (costo del Ejercicio 18). Comparalo con `sklearn.linear_model.Lasso`: ¿qué costo minimiza sklearn? Después duplicá dos veces una columna de *Prostate*, o sea tres copias idénticas, y probá distintos órdenes de barrido e inicializaciones. ¿Qué devuelve sklearn? Repetí con Ridge y compará con el Ejercicio 14.

Ejercicio 25 ★

Propio · Ejercicios 3 y 4

Pérdida cuadrática vs. absoluta. Simulá $Y = 2 + 3X + \varepsilon$ con ε con colas pesadas (t de Student con 2 grados de libertad) y otra versión con 5% de outliers. Ajustá una recta minimizando cada pérdida (para la absoluta podés usar `QuantileRegressor(quantile=0.5, alpha=0)`). Compará los coeficientes en 200 repeticiones y el error en un test grande, medido con cada pérdida. Verificá numéricamente los resultados del Ejercicio 3 simulando la tabla.

Resultados

1. (a) $\mathbf{U}^T\mathbf{U} = \mathbf{I}_2$; $\mathbf{U}\mathbf{U}^T = \begin{pmatrix} 1/2 & 1/2 & 0 \\ 1/2 & 1/2 & 0 \\ 0 & 0 & 1 \end{pmatrix} \neq \mathbf{I}_3$. (b) $\text{tr} = 2$. (c) $(2,2,2)^T$: proyección sobre el espacio columna. (d) $\mathbf{U}\mathbf{U}^T = \mathbf{I}$ solo si $\mathbf{U}$ es cuadrada ($N = p$).

2. (a) $\mathbf{X}^T\mathbf{X} = \begin{pmatrix} 5 & 4 \\ 4 & 5 \end{pmatrix}$, autovalores $9, 1 \Rightarrow d = (3,1)$. (b) $\mathbf{U} = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}$; $\mathbf{X}$ tiene un autovalor negativo (-1). (c) i V, ii V, iii V, iv V (porque $\mathbf{X}^T = \mathbf{X}$), v V, vi F: $\frac{1}{\sqrt{2}}\begin{pmatrix} 3 & 3 \\ 1 & -1 \end{pmatrix}$, vii V, viii F: $\begin{pmatrix} 2 & -1 \\ 1 & -2 \end{pmatrix}$. (d) $\mathbf{A}\mathbf{A}^T = \begin{pmatrix} 17 & 8 \\ 8 & 17 \end{pmatrix}$, $d = (5,3)$.

3. (a) Cuadrática: $f(0) = 1{,}1$, $f(1) = 3{,}4$. Absoluta: $f(0) = f(1) = 1$. 0-1: $f(0) = f(1) = 1$. (b) 9,665; 1,75; 0,55. (c) $2{,}25 > 1{,}75$. (d) En $X = 1$, por el valor 10: la media se va hacia la cola.

4. (b) $P(Y \leq c \mid x) = P(Y \geq c \mid x)$, o sea $F_{Y|x}(c) = 1/2$. (c) La mediana condicional. (d) El cuantil τ: $F_{Y|x}(c) = \tau$; regresión cuantílica. (e) Con colas pesadas u outliers en Y, o si el costo real es lineal en el error.

5. (a) Predecir enfermo si $q > 1/11 \approx 0{,}091$; con 0-1, si $q > 1/2$. (b) Riesgos (1,1; 1,3; 0,8): se predice la clase 3. Con 0-1, la clase 1.

6. (a) $\mathbf{X}^T\mathbf{X} = \begin{pmatrix} 4 & 6 \\ 6 & 14 \end{pmatrix}$, $\mathbf{X}^T\mathbf{y} = (12,25)^T$. (b) $\hat{\beta} = (0{,}9;\ 1{,}4)$. (c) $\hat{\mathbf{y}} = (0{,}9;\ 2{,}3;\ 3{,}7;\ 5{,}1)$, $\mathbf{e} = (0{,}1;\ 0{,}7;\ -1{,}7;\ 0{,}9)$: suman 0 y son ortogonales a x. (d) $\text{diag}(\mathbf{H}) = (0{,}7;\ 0{,}3;\ 0{,}3;\ 0{,}7)$, $\text{tr} = 2$, $\text{RSS} = 4{,}2$.

7. (a) $\nabla = -2\mathbf{X}^T(\mathbf{y} - \mathbf{X}\beta)$, hessiano $2\mathbf{X}^T\mathbf{X} \succeq 0$. (c) (0,48; 1,0) y (0,6432; 1,3248). (d) $\lambda = 9 \pm \sqrt{61}$, $\eta_{\max} \approx 0{,}0595$. (e) Con 0,05 converge oscilando; con 0,07 diverge.

8. (b) $0{,}7\sigma^2$; $0{,}2\sigma^2$; $-0{,}3\sigma^2$. (c) $\hat{\sigma}^2_{MV} = \text{RSS}/N$. (d) Es sesgado; el insesgado da $\text{RSS}/(N-2) = 2{,}1$. (e) MCO tiene mínima varianza entre los lineales insesgados; no dice nada de los sesgados.

9. (a) $\begin{pmatrix} N & 0 & 0 \\ 0 & N & N\rho \\ 0 & N\rho & N \end{pmatrix}$. (b) $\hat{\beta}_0 = \bar{y} = 0$, así que $\hat{\beta}_0 = 0$ y $\hat{\beta}_0 = \bar{y}$ son equivalentes; $\hat{\beta}_1 = \dfrac{\sum x_{i1}y_i - \rho\sum x_{i2}y_i}{N(1-\rho^2)}$ y $\hat{\beta}_2$ análogo. (c) 5,26 y 50,25. (d) $1 \pm \rho$. (e) $\hat{\beta}_1 + \rho\,\hat{\beta}_2$.

10. (a) Rango 1. (b) $\beta_1 + \beta_2 = \mathbf{x}^T\mathbf{y}/\mathbf{x}^T\mathbf{x} = 1{,}7$. (c) $d_1 = \sqrt{20}$, $v_1 = (1,1)/\sqrt{2}$, $\hat{\beta} = (0{,}85;\ 0{,}85)$: es la de norma mínima.

11. (c) Factores para $\lambda = 1$: (0,941; 0,8; 0,2); df = 3; 1,941; 1,359; 0,715. (d) La de menor d_j, que corresponde al menor autovalor de $\mathbf{X}^T\mathbf{X}$.

12. (a) $\beta_1 = \beta_2 = c/2$. (b) $\{\beta_1, \beta_2 \geq 0,\ \beta_1 + \beta_2 = c\}$ (un segmento). (c) La región L1 tiene vértices sobre los ejes.

13. (a) $\mathbf{x}^T\mathbf{y}/(\mathbf{x}^T\mathbf{x} + \lambda)$. (b) 1,7; 1,133; 0,85. (c) Tiende a 0; queda $\mathbf{x}^T\mathbf{x}/(\mathbf{x}^T\mathbf{x} + \lambda)$ de $\hat{\beta}^{ols}$.

14. (a) $\mathbf{x}^T\mathbf{y}/(2\,\mathbf{x}^T\mathbf{x} + \lambda)$. (b) 0,68 cada uno, suma 1,36 (contra 1,133): la penalidad sobre la suma es menor si se reparte. (c) $\mathbf{x}^T\mathbf{y}/(m\,\mathbf{x}^T\mathbf{x} + \lambda)$.

15. (a) $a = \sqrt{\lambda}$, $b = 0$. (b) Agregar $\sqrt{\lambda}\,\beta^0$ al final de $\tilde{\mathbf{y}}$ (con $a = \sqrt{\lambda}$). (c) No: la aumentación solo agrega términos cuadráticos en β, nunca $|\beta_j|$. (d) $\tilde{\mathbf{X}} = \begin{pmatrix} \mathbf{X} \\ \sqrt{\lambda_2}\mathbf{I} \end{pmatrix}$, $\tilde{\mathbf{y}} = \begin{pmatrix} \mathbf{y} \\ 0 \end{pmatrix}$, Lasso con λ_1.

16. (a) Sesgo $(s-1)\beta_j$; varianza $s^2\sigma^2/N$; $\text{ECM} = (1-s)^2\beta_j^2 + s^2\sigma^2/N$. (b) $\lambda^* = \sigma^2/\beta_j^2 > 0$ (si $\beta_j \neq 0$); no se puede calcular, depende de cantidades desconocidas. (c) Ridge es sesgado. (d) Entrenamiento: crece siempre; test: U; varianza: decrece siempre; sesgo^2: crece siempre; irreducible: constante.

17. (b) 2; 0; $-1{,}5$. (c) $a/(1+\lambda)$: recta de pendiente menor que 1, nunca da cero. (d) $a = \frac{1}{N}\mathbf{x}_j^T r^{(j)}$, la correlación de $\mathbf{x}_j$ con el residuo parcial.

18. (a) 2. (b) (1,5; 0; 0) ya desde el primer barrido. (c) (0; 0; 1,5) y (0,5; 0,5; 0,5). (d) $R = 1{,}375$ en los tres; soluciones: $\beta_j \geq 0$ con $\sum_j \beta_j = 1{,}5$. (e) $2/3{,}5 \approx 0{,}571$ cada uno. (f) $\beta_1 = c$, $\beta_2 = \beta_3 = 0$.

19. (a) $\mathbf{x}_j^T \mathbf{x}_j = N$, $\mathbf{x}_j^T \mathbf{x}_k = 0$, $\mathbf{1}^T \mathbf{x}_j = 0$. (b) $\mathbf{X}^T\mathbf{X} = N\mathbf{I}$, $(\mathbf{X}^T\mathbf{X})^{-1} = \frac{1}{N}\mathbf{I}$, $(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T = \frac{1}{N}\mathbf{X}^T$, $\hat{\beta} = \frac{1}{N}\mathbf{X}^T\mathbf{y}$, $\hat{\beta}_0 = \bar{y}$, $\hat{\beta}_j = \frac{1}{N}\sum_i x_{ij} y_i$. (c) Es la pendiente de la regresión simple de y sobre x_j. (d) No cambia (en el caso correlacionado, sí). (e) $\hat{\beta}_j/(1 + \lambda/N)$. (f) $S(\hat{\beta}_j, \lambda)$. (g) MCO $(2, 2, 1)$; Ridge (2; 1; 0,5); Lasso (2; 0,5; 0).

20. (a) $\lambda = \sigma^2/\tau$. (b) $\lambda = 2\sigma^2/b$. (c) No: la media posterior promedia sobre toda la posterior, que no tiene masa puntual en 0.

21. 1 Breiman (efecto Rashomon); 2 Breiman; 3 Efron; 4 Efron; 5 Donoho (Tukey, 1962); 6 Donoho (*science about data science*); 7 Efron (*concept drift*); 8 Breiman.