Guía de práctica: 2do parcial

Aprendizaje Automático — 2C 2026

Métodos lineales para clasificación · Evaluación de modelos · Papers (Simmons, Ball, Saeb)

Cómo usar esta guía. Mismo formato que la guía del recuperatorio: los ejercicios están en orden y cada bloque va de cuentas chicas a ejercicios del nivel del parcial.

- Dificultad: ★ directo, ★★ desarrollo, ★★★ nivel parcial o más.
- Fuentes: *Cátedra* (notebooks de clasificación y evaluación), ESL, ISLR, Bishop, o *Propio*.
- La Parte II es para la compu y está en el notebook `Guia_B_computadora.ipynb`.
- Al final están los **resultados** (sin desarrollo).

Notación: $G \in \{1, \dots, K\}$, $\pi_k = P(G = k)$, $f_k(x)$ es la densidad de $X \mid G = k$ y $p(x; \beta) = P(G = 1 \mid X = x)$ en el caso binario, con $y_i \in \{0, 1\}$.

Parte I — A mano

Bloque 1. Regresión lineal sobre indicadoras

Ejercicio 1 ★

Propio

Datos 1D: $x = (1, 2, 3, 4, 5, 6)$, $y = (0, 0, 0, 1, 1, 1)$. Se ajusta $f(x) = \beta_0 + \beta_1 x$ por cuadrados mínimos y se clasifica como 1 si $\hat{f}(x) > 0{,}5$.

a) Calculá $\hat{\beta}$ y la frontera de decisión. Calculá $\hat{f}(0)$ y $\hat{f}(7)$. ¿Se puede interpretar $\hat{f}$ como una probabilidad?

b) Agregá el punto $(x, y) = (20, 1)$, que es de la clase 1 y no es ambiguo. Recalculá $\hat{\beta}$ y la frontera. ¿Cuántos puntos de entrenamiento quedan mal clasificados?

c) En una oración: ¿por qué un punto "fácil" mueve la frontera?

Ejercicio 2 ★★

Propio · ESL 4.2

Masking. Tres clases en 1D: $x = (-1, -1, 0, 0, 1, 1)$ con clases $(1, 1, 2, 2, 3, 3)$. Se ajustan tres regresiones lineales sobre las indicadoras Y_1, Y_2, Y_3 y se clasifica con $\hat{G}(x) = \arg\max_k \hat{f}_k(x)$.

a) Calculá $\hat{f}_1$, $\hat{f}_2$ y $\hat{f}_3$.

b) Mostrá que la clase 2 nunca es la única ganadora.

c) Mostrá que, en general, si el modelo tiene intercepto, $\sum_k \hat{f}_k(x) = 1$ para todo x. (Pista: $\sum_k Y_k = 1$.)

d) Agregá x^2 como predictor. Calculá de nuevo las $\hat{f}_k$ (salen exactas) y las fronteras de decisión. ¿Se resolvió el masking?

Bloque 2. Bayes, LDA y QDA

Ejercicio 3 ★

ISLR 4.2 y 4.10 (adaptado)

Dos clases en 1D con $X \mid G = k \sim N(\mu_k, \sigma^2)$ (varianza común) y priors π_1, π_2.

a) Mostrá que clasificar con la regla de Bayes equivale a maximizar $\delta_k(x) = x\frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log \pi_k$.

b) Mostrá que la frontera es $x^* = \frac{\mu_1 + \mu_2}{2} + \frac{\sigma^2 \log(\pi_2/\pi_1)}{\mu_1 - \mu_2}$.

c) Con $\mu_1 = 0$, $\mu_2 = 4$, $\sigma^2 = 4$, $\pi_1 = 0{,}8$: calculá x^*. ¿Y con priors iguales? ¿Hacia dónde se corre la frontera y por qué?

d) Si σ^2 crece y los priors siguen desiguales, ¿la frontera se corre más o menos?

Ejercicio 4 ★ ISLR 4.7

Se quiere predecir si una empresa pagará dividendos (Sí/No) a partir de X, la ganancia porcentual del año anterior. Entre las que pagaron, $\bar{X} = 10$; entre las que no, $\bar{X} = 0$. La varianza en ambos grupos es $\hat{\sigma}^2 = 36$ y el 80% pagó dividendos. Suponiendo normalidad, calculá la probabilidad de que una empresa con $X = 4$ pague dividendos.

Ejercicio 5 ★★ Cátedra

LDA en p dimensiones.

a) Escribí $\log \frac{P(G=k|x)}{P(G=l|x)}$ usando Bayes. Indicá qué términos se cancelan y por qué. ¿Cuál se cancela solo porque $\mathbf{\Sigma}_k = \mathbf{\Sigma}$?

b) Llegá a una expresión lineal en x y deducí $\delta_k(x) = x^T\mathbf{\Sigma}^{-1}\mu_k - \frac{1}{2}\mu_k^T\mathbf{\Sigma}^{-1}\mu_k + \log \pi_k$.

c) En QDA, escribí $\delta_k(x)$. ¿Qué términos ya no se cancelan?

d) Contá los parámetros del modelo generativo para $p = 10$, $K = 3$: priors, medias y covarianza(s), en LDA y en QDA. ¿Cuántos parámetros tiene una regresión logística multiclase con los mismos p y K?

e) Clasificá LDA, QDA y regresión logística en generativos o discriminativos. Con un LDA ya entrenado, ¿cómo generarías un conjunto de datos sintético (x, g)? ¿Se puede hacer lo mismo con una logística?

Ejercicio 6 ★★ Propio

LDA a mano. Datos en $\mathbb{R}^2$:

Clase 1: $(-2,-1)$, $(0,0)$, $(1,-1)$, $(1,2)$ Clase 2: $(2,-2)$, $(2,1)$, $(3,0)$, $(5,1)$

a) Calculá $\hat{\pi}_k$, $\hat{\mu}_k$ y $\hat{\mathbf{\Sigma}} = \frac{1}{N-K}\sum_k \sum_{g_i=k}(x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T$.

b) Calculá $\hat{\mathbf{\Sigma}}^{-1}$ y la ecuación de la frontera de decisión. ¿Es perpendicular a $\hat{\mu}_2 - \hat{\mu}_1$?

c) Clasificá $x_0 = (2,2)$. Calculá también la distancia euclídea de x_0 a cada centroide y la distancia de Mahalanobis $(x_0 - \hat{\mu}_k)^T\hat{\mathbf{\Sigma}}^{-1}(x_0 - \hat{\mu}_k)$. ¿Cuál decide LDA?

d) Si los priors fueran $\pi_1 = 0{,}2$ y $\pi_2 = 0{,}8$, ¿cómo cambia la frontera? ¿Cómo se clasifica x_0?

Ejercicio 7 ★★ Cátedra

Esferización. Con $\hat{\mathbf{\Sigma}} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ del ejercicio anterior:

a) Encontrá la descomposición espectral $\hat{\mathbf{\Sigma}} = \mathbf{U}\mathbf{D}\mathbf{U}^T$.

b) Sea $X^* = \mathbf{D}^{-1/2}\mathbf{U}^T X$. Mostrá que $\mathrm{Var}(X^*) = \mathbf{I}$.

c) Transformá $\hat{\mu}_1$, $\hat{\mu}_2$ y $x_0 = (2,2)$. Clasificá x_0 con la regla $\arg\min_k\{\frac{1}{2}\|x_0^* - \hat{\mu}_k^*\|^2 - \log \hat{\pi}_k\}$ y verificá que coincide con el ejercicio anterior. ¿Qué relación hay entre $\|x_0^* - \hat{\mu}_k^*\|^2$ y la distancia de Mahalanobis?

d) ¿En qué se diferencia de estandarizar cada variable por separado? Calculá la covarianza que quedaría después de estandarizar.

Ejercicio 8 ★★

ISLR 4.3 (con números)

QDA en 1D. $X \mid G = 1 \sim N(0,1)$ y $X \mid G = 2 \sim N(0,4)$.

a) Escribí $\delta_1(x)$ y $\delta_2(x)$ de QDA. ¿Por qué la frontera no es lineal?

b) Con priors iguales, encontrá la región donde se clasifica como clase 1.

c) Con $\pi_1 = 0{,}2$, ¿qué pasa? ¿Para qué valores de π_1 la clase 1 no se predice nunca?

d) ¿Qué haría LDA con estos datos? ¿Por qué?

Bloque 3. Regresión logística

Ejercicio 9 ★

ISLR 4.1, 4.6, 4.9 · Bishop 4.12

a) Sea $\sigma(z) = \frac{e^z}{1+e^z}$. Mostrá que $p = \sigma(z) \iff \log \frac{p}{1-p} = z$, que $1 - \sigma(z) = \sigma(-z)$ y que $\sigma'(z) = \sigma(z)(1 - \sigma(z))$.

b) Si los odds de incumplir un pago son 0,37, ¿qué fracción incumple? Si la probabilidad es 16%, ¿cuáles son los odds?

c) Una logística da $\hat{\beta}_0 = -6$, $\hat{\beta}_1 = 0{,}05$ (horas de estudio) y $\hat{\beta}_2 = 1$ (promedio). Calculá la probabilidad de sacar A para 40 horas y promedio 3,5. ¿Cuántas horas hacen falta para llegar al 50%?

d) Interpretá $e^{\hat{\beta}_1}$: ¿qué le pasa a los odds por cada hora extra?

Ejercicio 10 ★★

Propio · ESL 4.4.5

LDA también da log-odds lineales.

a) Con los datos del Ejercicio 3(c), escribí $\log \frac{P(G=1|x)}{P(G=2|x)} = \beta_0 + \beta_1 x$. Calculá β_0 y β_1 y verificá que se anula en el x^* del Ejercicio 3.

b) Si los datos vienen exactamente de ese modelo y ajustás una regresión logística con N muy grande, ¿qué coeficientes esperás?

c) Si las dos tienen la misma forma funcional, ¿por qué dan resultados distintos en la práctica? Mencioná qué usa cada una para estimar y cuál es más sensible a outliers lejos de la frontera.

Ejercicio 11 ★★

Cátedra · Bishop 4.13

Regresión logística binaria, $p_i = p(x_i; \beta) = \sigma(\beta^T x_i)$, con x_i que incluye un 1.

a) A partir de $P(y_i \mid x_i) = p_i^{y_i}(1 - p_i)^{1-y_i}$, llegá a $\ell(\beta) = \sum_i \{y_i \beta^T x_i - \log(1 + e^{\beta^T x_i})\}$.

b) Derivá el gradiente $\sum_i x_i(y_i - p_i)$ y el hessiano $-\sum_i x_i x_i^T p_i(1 - p_i)$. ¿Qué dimensión tiene cada uno? ¿Qué es $x_i x_i^T$?

c) Mostrá que $v^T \mathbf{H} v \leq 0$ para todo v. ¿Qué implica para la optimización?

d) Interpretá la primera ecuación de $\nabla \ell = 0$. Para el modelo con solo intercepto, calculá $\hat{\beta}_0$ en función de $\bar{y}$. Evaluá con $\bar{y} = 0{,}2$.

e) ¿Qué relación hay entre $-\ell(\beta)$ y la entropía cruzada?

Ejercicio 12 ★★ ISLR 4.12

Clasificás frutas en naranjas y manzanas con $X \in \mathbb{R}$. Tu modelo es $P(\text{naranja} \mid x) = \sigma(\hat{\beta}_0 + \hat{\beta}_1 x)$. Un amigo usa softmax:

$$P(\text{naranja} \mid x) = \frac{e^{\hat{\alpha}_{n0}+\hat{\alpha}_{n1}x}}{e^{\hat{\alpha}_{n0}+\hat{\alpha}_{n1}x} + e^{\hat{\alpha}_{m0}+\hat{\alpha}_{m1}x}}.$$

a) ¿Cuáles son los log-odds de naranja contra manzana en tu modelo? ¿Y en el de tu amigo?

b) Si $\hat{\beta}_0 = 2$ y $\hat{\beta}_1 = -1$, ¿qué podés decir de los coeficientes de tu amigo? Sé lo más específico posible.

c) Si tu amigo obtiene $\hat{\alpha}_{n0} = 1{,}2$, $\hat{\alpha}_{n1} = -2$, $\hat{\alpha}_{m0} = 3$, $\hat{\alpha}_{m1} = 0{,}6$, ¿cuáles son tus coeficientes?

d) ¿Con qué frecuencia coinciden las predicciones de los dos modelos en un test? ¿Por qué en clase se usa una clase de referencia?

Ejercicio 13 ★★ Cátedra · intermezzo Newton-Raphson

a) Aplicá Newton-Raphson a $f(x) = x^2 - 2$ desde $x_0 = 1$: tres iteraciones.

b) Para minimizar $g(x) = x - \log x$ $(x > 0)$, aplicá Newton sobre g'. Mostrá que la iteración es $x_{n+1} = 2x_n - x_n^2$. Hacé tres pasos desde $x_0 = 0{,}5$. Mostrá que $x_{n+1} - 1 = -(x_n - 1)^2$: ¿qué dice esto de la velocidad de convergencia?

c) Desde $x_0 = 2$, ¿qué pasa?

d) Escribí la versión multivariada. ¿Qué tiene que cumplir el hessiano?

Ejercicio 14 ★★★ Propio

Newton-Raphson para la logística, a mano. Datos: $x = (-2, -1, 1, 2)$, $y = (0, 1, 0, 1)$. Modelo sin intercepto: $p_i = \sigma(\beta x_i)$.

a) Escribí $\ell'(\beta)$ y $\ell''(\beta)$.

b) Desde $\beta^{(0)} = 0$, hacé un paso de Newton.

c) Hacé un segundo paso (con calculadora).

d) *IRLS*: en $\beta^{(0)} = 0$, calculá $\mathbf{W}$ y $z = \mathbf{X}\beta^{(0)} + \mathbf{W}^{-1}(\mathbf{y} - \mathbf{p})$. Resolvé el problema de cuadrados mínimos ponderados $\min_\beta \sum_i w_i(z_i - \beta x_i)^2$ y verificá que da lo mismo que (b).

e) El estimador de MV es $\hat{\beta} \approx 0{,}4196$. Interpretalo con odds.

Ejercicio 15 ★★ Bishop 4.14 · Cátedra

Separabilidad y regularización. Mismos x pero $y = (0, 0, 1, 1)$.

a) Calculá $\ell(\beta)$ para $\beta = 0, 1, 2, 5, 10$. Mostrá que ℓ crece con $\beta > 0$ y que su supremo (0) no se alcanza. ¿Existe el estimador de MV?

b) Hacé dos pasos de Newton desde 0. ¿Qué tendencia ves?

c) Con penalidad L2 se maximiza $\ell(\beta) - \lambda\beta^2$. Escribí gradiente, hessiano y la actualización de Newton. ¿Por qué ahora el máximo existe? (El resultado con $\lambda = 1$ está en los resultados para chequear.)

d) ¿Por qué Newton-Raphson no se puede usar directamente con penalidad L1?

e) ¿Por qué no se penaliza el intercepto y se estandarizan los predictores?

Ejercicio 16 ★★ Cátedra

IRLS en forma matricial.

a) A partir de $\beta^{new} = \beta^{old} + (\mathbf{X}^T\mathbf{W}\mathbf{X})^{-1}\mathbf{X}^T(\mathbf{y} - \mathbf{p})$, mostrá que $\beta^{new} = (\mathbf{X}^T\mathbf{W}\mathbf{X})^{-1}\mathbf{X}^T\mathbf{W}z$, con $z = \mathbf{X}\beta^{old} + \mathbf{W}^{-1}(\mathbf{y} - \mathbf{p})$.

b) ¿Qué problema de optimización se resuelve en cada iteración? ¿Qué cambia de una iteración a la otra?

c) ¿Qué pasa con $\mathbf{W}$ cuando algunos p_i se acercan a 0 o a 1? ¿Y con $\mathbf{X}^T\mathbf{W}\mathbf{X}$? Relacionalo con el ejercicio anterior.

Bloque 4. Evaluación de modelos

Ejercicio 17 ★ Cátedra

Sea $X \in \{0, 1\}$ con $P(X = 0) = P(X = 1) = 1/2$. Si $X = 0$, Y vale 0 o 2 con probabilidad $1/2$ cada uno. Si $X = 1$, Y vale 1, 3 o 5 con probabilidad $1/3$ cada uno.

a) Calculá $f(x) = \mathbb{E}[Y \mid X = x]$ para $x = 0, 1$.

b) Calculá el error irreducible $\int \mathrm{Var}(Y \mid X = x)\, p(x)\, dx$.

c) Calculá el EPE del predictor constante $c = \mathbb{E}[Y]$.

d) Verificá que $\mathrm{EPE}(c) = \int (c - f(x))^2 p(x)\, dx +$ error irreducible.

Ejercicio 18 ★★ Cátedra

Sean $Y_1, \ldots, Y_N$ independientes con media μ y varianza σ^2. Para $\lambda \geq 0$ se estima μ con $\hat{\mu}_\lambda = \frac{1}{N+\lambda} \sum_i Y_i$.

a) Calculá el sesgo y la varianza de $\hat{\mu}_\lambda$.

b) Escribí el ECM como sesgo^2 + varianza.

c) ¿Qué pasa con cada término si $\lambda = 0$? ¿Y si $\lambda \to \infty$?

d) Encontrá el λ que minimiza el ECM. ¿Se puede usar en la práctica?

Ejercicio 19 ★★★ Cátedra · ESL 7.3

Sesgo-varianza y grados de libertad.

a) Con $Y = f(X) + \varepsilon$, $\mathbb{E}[\varepsilon] = 0$ y $\mathrm{Var}(\varepsilon) = \sigma_\varepsilon^2$, derivá $\mathrm{Err}(x_0) = \sigma_\varepsilon^2 + \text{sesgo}^2 + \text{varianza}$ con el truco de sumar y restar $\mathbb{E}[\hat{f}(x_0)]$. Justificá por qué se anula cada término cruzado.

b) Para MCO, $\hat{f}(x_0) = \mathbf{h}(x_0)^T\mathbf{y}$. Mostrá que $\mathrm{Var}(\hat{f}(x_0)) = \|\mathbf{h}(x_0)\|^2\sigma_\varepsilon^2$. ¿Qué supuestos usás?

c) Modelo con solo intercepto ($\mathbf{X} = \mathbf{1}$): calculá $\mathbf{H}$, sus elementos diagonales y su traza. Obtené $\mathrm{Var}(\hat{f}(x_i))$ y compará con $\frac{p}{N}\sigma_\varepsilon^2$.

d) Para Ridge, $\mathrm{df}(\alpha) = \sum_j \frac{d_j^2}{d_j^2 + \alpha}$. Con $d = (10;\ 1;\ 0{,}1)$, calculá df para $\alpha = 0, 1, 100$. ¿Qué direcciones apaga primero la regularización?

Ejercicio 20 ★ Cátedra · ISLR 6.3

a) Para cada situación, indicá si se calcula o se estima $\overline{err}$, Err_τ, Err, Err_{in} o CV. ¿Qué está fijo y qué es aleatorio?

i. Se entrena con 800 casos y se mide el error en esos mismos 800.

ii. Se entrena con 800 casos y se mide el error en 200 casos nuevos.

iii. Se repite lo anterior con 50 conjuntos de entrenamiento distintos del mismo tamaño y se promedia.

iv. Se entrena con 800 casos y se mide el error en los mismos x_i, pero con nuevas mediciones de y.

v. Se dividen los 800 casos en 5 partes, se entrena 5 veces dejando una afuera y se promedian las pérdidas de cada caso.

b) (ISLR 6.3) Lasso en forma restringida, $\sum_j |\beta_j| \leq s$. Cuando s crece desde 0, ¿qué pasa con el RSS de entrenamiento, el RSS de test, la varianza, el sesgo^2 y el error irreducible?

Ejercicio 21 ★★

Cátedra · ESL 7.3

Validación cruzada.

a) Una CV con 3 folds de distinto tamaño da estas pérdidas por muestra: fold A: $1, 3$; fold B: $2, 2$; fold C: $0, 0, 0, 0, 1, 1$. Calculá $CV(\hat{f})$ promediando sobre las muestras.

b) Calculá el promedio de los errores medios de cada fold. ¿Por qué difieren? ¿Cuándo coincidirían?

c) Modelo con solo intercepto. Mostrá que el residuo de LOO es $y_i - \bar{y}_{(-i)} = \dfrac{y_i - \bar{y}}{1 - 1/N}$, que es el caso $\dfrac{y_i - \hat{f}(x_i)}{1 - H_{ii}}$ de ESL 7.3.

d) Con $y = (2, 4, 6, 8, 10)$, calculá CV_{LOO} usando (c) y el error de entrenamiento. ¿Cuál es mayor y por qué?

e) ¿Qué se gana y qué se pierde con K chico frente a LOO? ¿Por qué la CV estima Err y no Err_τ?

Ejercicio 22 ★★★

Propio · Ball, Saeb, Simmons

¿Qué está mal? Para cada escenario, decí cuál es el problema, si la estimación queda optimista o pesimista y cómo lo arreglarías.

a) 50 pacientes y 10 000 genes. Con los 50 se eligen los 20 genes más correlacionados con la respuesta. Después se hace CV de 10 folds de una logística con esos 20 genes: accuracy 90%. ¿Qué esperarías si repetís todo con una respuesta al azar?

b) Se prueban 1000 combinaciones de hiperparámetros con CV de 5 folds y se reporta el mejor promedio de CV como desempeño esperado.

c) 25 pacientes con acelerómetro y 2000 ventanas cada uno. Se hace CV de 10 folds mezclando al azar las ventanas. El uso real es diagnosticar a pacientes nuevos.

d) Un investigador mide dos variables respuesta, testea con 20 personas por grupo, agrega 10 más si $p > 0{,}05$ y controla por género si eso ayuda. Reporta solo lo significativo.

e) Se imputan faltantes con la media y se estandariza usando todo el dataset; después se separa train/test.

f) El modelo elegido da mal en test, entonces se vuelve a cambiar el modelo y se mide de nuevo en el mismo test hasta que da bien.

Ejercicio 23 ★ Papers

Asigná cada afirmación a **Simmons** et al. (2011), **Ball** et al. (2020) o **Saeb** et al. (2017).

Afirmación	Autor
1. La validación cruzada solo tiene sentido si la relación entre entrenamiento y validación imita la relación entre entrenamiento y los datos del uso real.	
2. Si se reparten al azar los registros, y no las personas, entre entrenamiento y validación, el modelo puede aprender a reconocer a cada persona y la precisión queda muy inflada.	
3. Una revisión de la literatura con sensores y smartphones encontró que casi la mitad de los estudios usaba la estrategia optimista.	
4. Si se eligen las variables y se evalúa el modelo con la misma muestra, se puede obtener alta precisión aun con datos completamente aleatorios, y más cuantas más variables haya.	
5. Para detectar el problema conviene correr el procedimiento completo con la variable respuesta permutada y comparar con la tasa base.	
6. Una alternativa es elegir las variables por teoría o estudios previos, preregistrarlas y usar la muestra solo para evaluar.	
7. Medir varias variables dependientes, decidir sobre la marcha cuándo dejar de juntar datos y agregar covariables puede llevar la tasa de falsos positivos muy por encima del 5% nominal.	
8. Los autores deberían fijar de antemano la regla para dejar de recolectar datos, listar todas las variables medidas y reportar todas las condiciones experimentales.	

Parte II — En la computadora

Notebook `Guia_B_computadora.ipynb`. Cada ejercicio tiene una celda de preparación y el resto lo completás vos.

Ejercicio 24 ★★ Cátedra · ESL Fig. 4.2–4.3

Indicadoras vs. LDA vs. QDA. Generá tres clases gaussianas en $\mathbb{R}^2$ con medias alineadas, como en la Fig. 4.2 de ESL. Ajustá regresión sobre indicadoras, tu propia implementación de LDA y QDA (con las funciones discriminantes) y las versiones de `sklearn`. Graficá las fronteras. ¿Dónde aparece el masking? ¿Se arregla agregando términos cuadráticos? ¿Coinciden tus parámetros con los de `sklearn`?

Ejercicio 25 ★★ Cátedra

Logística por Newton/IRLS. Implementá la logística binaria con IRLS desde cero. Compará coeficientes con `LogisticRegression(penalty=None)`. Registrá $\ell(\beta)$ por iteración y comparalo con ascenso por gradiente: ¿cuántas iteraciones necesita cada uno? Después usá datos separables y mirá qué pasa con $\|\beta\|$ y con $\mathbf{W}$. Agregá penalidad L2 y repetí.

Ejercicio 26 ★★★ Cátedra · ESL Fig. 7.1

Sesgo-varianza por simulación. Con $f(x) = \sin(2\pi x)$, $\sigma_\varepsilon = 0{,}3$ y $N = 30$, ajustá polinomios de grado 1 a 12 en 200 conjuntos de entrenamiento distintos. En una grilla de x_0, estimá sesgo^2, varianza y Err, y graficá en función del grado. Superponé $\overline{err}$ y Err_τ de cada simulación (curvas

finas) y sus promedios (curvas gruesas). Para MCO, verificá que la varianza promedio en los x_i de entrenamiento es $\frac{p}{N}\sigma_\varepsilon^2$.

Ejercicio 27 ★★★

Ball · Saeb · notebook de evaluación

Evaluaciones mal hechas.

a) *Random data test* (Ball): con X de ruido puro ($N = 100$, $p = 5000$) e y binaria al azar, elegí las 20 variables más correlacionadas con y usando todos los datos y después hacé CV. Repetí haciendo la selección *dentro* de cada fold (con `Pipeline`). Compará con el 50%.

b) *Optimismo por selección*: repetí la simulación de clase (1000 configuraciones, 5 folds, desempeño real 0,8) y medí cuánto "corrige" el mejor modelo al evaluarlo en datos nuevos. Hacelo para 10, 100 y 1000 configuraciones.

c) *Record-wise vs. subject-wise* (Saeb): simulá 20 sujetos con 100 registros cada uno. Cada sujeto tiene un efecto propio fuerte y la variable respuesta depende poco de x. Compará `KFold` con `GroupKFold`.

Resultados

1. (a) $\hat\beta = (-0{,}4;\ 9/35 \approx 0{,}257)$, frontera $x = 3{,}5$; $\hat f(0) = -0{,}4$, $\hat f(7) = 1{,}4$: no son probabilidades. (b) $\hat\beta \approx (0{,}301;\ 0{,}0461)$, frontera $\approx 4{,}31$; queda mal clasificado $x = 4$. (c) MCO penaliza el residuo cuadrático del punto lejano aunque esté bien clasificado.

2. (a) $\hat f_1 = \frac{1}{3} - \frac{x}{2}$, $\hat f_2 = \frac{1}{3}$, $\hat f_3 = \frac{1}{3} + \frac{x}{2}$. (b) $\hat f_2 \le \max(\hat f_1, \hat f_3)$, con igualdad solo en $x = 0$. (d) $\hat f_1 = \frac{x^2 - x}{2}$, $\hat f_2 = 1 - x^2$, $\hat f_3 = \frac{x^2 + x}{2}$; fronteras $x = \pm 2/3$; la clase 2 gana en $(-2/3, 2/3)$.

3. (c) $x^* = 2 + \ln 4 \approx 3{,}39$; con priors iguales, $x^* = 2$. Se corre hacia μ_2 porque la clase 1 es más probable a priori. (d) Se corre más: el desplazamiento es proporcional a σ^2.

4. $\approx 0{,}752$.

5. (a) Se cancela el denominador de Bayes; con $\mathbf{\Sigma}$ común, también $\log|\mathbf{\Sigma}|$ y el término $x^T\mathbf{\Sigma}^{-1}x$. (d) LDA: $2 + 30 + 55 = 87$; QDA: $2 + 30 + 3 \cdot 55 = 197$; logística: $(K-1)(p+1) = 22$. (e) LDA y QDA son generativos; la logística, discriminativa. Con LDA: muestrear $g \sim \hat\pi$ y luego $x \sim N(\hat\mu_g, \hat{\mathbf{\Sigma}})$. Con la logística no, porque no modela $p(x)$.

6. (a) $\hat\pi = (1/2, 1/2)$, $\hat\mu_1 = (0,0)$, $\hat\mu_2 = (3,0)$, $\hat{\mathbf{\Sigma}} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$. (b) $\hat{\mathbf{\Sigma}}^{-1} = \frac{1}{3}\begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}$; frontera $2x_1 - x_2 = 3$; normal $(2, -1)$, no es paralela a $(3,0)$, así que la frontera no es perpendicular a $\hat\mu_2 - \hat\mu_1$. (c) Clase 1. Euclídea: $\sqrt{8} \approx 2{,}83$ contra $\sqrt{5} \approx 2{,}24$ (más cerca de la clase 2); Mahalanobis: $8/3$ contra $14/3$. LDA decide por Mahalanobis. (d) $2x_1 - x_2 = 3 + \ln(1/4) \approx 1{,}61$: clase 2.

7. (a) Autovalores 3 y 1; $u_1 = (1,1)/\sqrt{2}$, $u_2 = (1,-1)/\sqrt{2}$. (c) $\hat\mu_1^* = 0$, $\hat\mu_2^* = (3/\sqrt{6},\ 3/\sqrt{2}) \approx (1{,}22;\ 2{,}12)$, $x_0^* \approx (1{,}63;\ 0)$; distancias^2 $8/3$ y $14/3$ (iguales a Mahalanobis): clase 1. (d) Estandarizando queda $\begin{pmatrix} 1 & 0{,}5 \\ 0{,}5 & 1 \end{pmatrix}$: la correlación sigue.

8. (b) $|x| < \sqrt{\frac{8}{3}\ln 2} \approx 1{,}36$. (c) $x^2 < \frac{8}{3}\left(\ln\frac{\pi_1}{\pi_2} + \ln 2\right)$: con $\pi_1 = 0{,}2$ nunca se predice la clase 1; pasa lo mismo para todo $\pi_1 \le 1/3$. (d) Las medias son iguales: LDA siempre predice la clase de mayor prior.

9. (b) 0,27 y 0,19. (c) $\approx 0{,}378$; 50 horas. (d) Los odds se multiplican por $e^{0{,}05} \approx 1{,}051$.

10. (a) $\beta_1 = -1$, $\beta_0 = 2 + \ln 4 \approx 3{,}39$. (b) Los mismos. (c) LDA usa también $p(x)$ (más eficiente si hay normalidad, pero sensible a outliers); la logística solo usa $P(G \mid x)$.

11. (b) Gradiente $(p+1) \times 1$, hessiano $(p+1) \times (p+1)$; $x_i x_i^T$ es un producto exterior. (c) ℓ es cóncava: todo máximo local es global. (d) $\sum y_i = \sum p_i$; $\hat\beta_0 = \log\frac{\bar y}{1-\bar y} = \ln(1/4) \approx -1{,}386$. (e) Son iguales.

12. (a) $\hat\beta_0 + \hat\beta_1 x$; $(\hat\alpha_{n0} - \hat\alpha_{m0}) + (\hat\alpha_{n1} - \hat\alpha_{m1})x$. (b) $\hat\alpha_{n0} - \hat\alpha_{m0} = 2$ y $\hat\alpha_{n1} - \hat\alpha_{m1} = -1$; los valores individuales no se identifican. (c) $\hat\beta_0 = -1{,}8$, $\hat\beta_1 = -2{,}6$. (d) Siempre (100%). La clase de referencia hace que los parámetros sean identificables.

13. (a) 1,5; 1,41667; 1,414216. (b) 0,75; 0,9375; 0,99609; convergencia cuadrática. (c) $x_1 = 0$: sale del dominio. (d) $\mathbf{x}_1 = \mathbf{x}_0 - \mathbf{H}^{-1}\nabla f$; el hessiano tiene que ser invertible (y de signo definido para garantizar un extremo).

14. (a) $\ell' = \sum x_i(y_i - p_i)$, $\ell'' = -\sum x_i^2 p_i(1-p_i)$. (b) 0,4. (c) $\approx 0{,}4195$. (d) $w_i = 1/4$, $z = (-2, 2, -2, 2)$, $\hat\beta = 0{,}4$. (e) Los odds se multiplican por $e^{0{,}42} \approx 1{,}52$ por unidad de x.

15. (a) $-2{,}773$; $-0{,}880$; $-0{,}290$; $-0{,}0135$; $-0{,}00009$: no existe el estimador de MV. (b) 1,2; 2,02; crece casi linealmente sin límite. (c) $\nabla = \sum x_i(y_i - p_i) - 2\lambda\beta$, $\mathbf{H} = -\sum x_i^2 p_i(1-p_i) - 2\lambda$; con $\lambda = 1$, $\hat\beta \approx 0{,}715$. (d) $|\beta|$ no es derivable en 0. (e) Para no depender del nivel de y ni de la escala de cada variable.

16. (b) Mínimos cuadrados ponderados de z sobre $\mathbf{X}$ con pesos $\mathbf{W}$; z y $\mathbf{W}$ dependen de β^{old}. (c) $w_i \to 0$: $\mathbf{X}^T\mathbf{W}\mathbf{X}$ queda casi singular.

17. (a) $f(0) = 1$, $f(1) = 3$. (b) $\frac{1}{2}(1 + \frac{8}{3}) = \frac{11}{6}$. (c) $c = 2$, EPE $= \frac{17}{6}$. (d) $1 + \frac{11}{6} = \frac{17}{6}$.

18. (a) Sesgo $-\frac{\lambda\mu}{N+\lambda}$, varianza $\frac{N\sigma^2}{(N+\lambda)^2}$. (b) ECM $= \frac{\lambda^2\mu^2 + N\sigma^2}{(N+\lambda)^2}$. (c) Con $\lambda = 0$: sesgo 0 y varianza σ^2/N; con $\lambda \to \infty$: sesgo$\to -\mu$ y varianza$\to 0$. (d) $\lambda^* = \sigma^2/\mu^2$; no se puede usar porque depende de μ y σ.

19. (b) Errores independientes y homocedásticos, $\mathbf{X}$ fija. (c) $\mathbf{H} = \frac{1}{N}\mathbf{1}\mathbf{1}^T$, $H_{ii} = \frac{1}{N}$, tr $= 1$; Var $= \sigma_\varepsilon^2/N$ $(p = 1)$. (d) 3; 1,5; 0,51. Primero apaga las de menor d_j.

20. (a) i: $\overline{err}$ (se calcula). ii: estima Err_τ. iii: estima Err. iv: estima Err_{in}. v: CV, que estima Err. (b) Entrenamiento: decrece siempre; test: U; varianza: crece siempre; sesgo^2: decrece siempre; irreducible: constante.

21. (a) $CV = 1$. (b) $\approx 1{,}44$; difieren porque los folds tienen distinto tamaño; coincidirían con folds iguales. (d) $CV_{LOO} = 12{,}5$, $\overline{err} = 8$. (e) K chico: menos varianza y menos cómputo, más sesgo. Estima Err porque cada fold entrena con un conjunto distinto: promedia sobre conjuntos de entrenamiento en vez de condicionar en un τ fijo.

22. (a) *Double dipping*: optimista; con datos al azar daría mucho más que 50%. Hay que elegir las variables dentro de cada fold. (b) Sesgo por elegir el máximo: optimista. Hace falta un test intocado o CV anidada. (c) Record-wise: optimista. Hay que usar CV por sujeto (GroupKFold). (d) Grados de libertad del investigador: falsos positivos muy por encima del 5%. Reglas de Simmons: fijar la parada y reportar todas las variables y el análisis sin covariable. (e) Fuga de información del test: levemente optimista. Hay que ajustar el preprocesamiento solo con train, dentro de la CV. (f) El test pasa a ser validación: optimista. Hace falta un test nuevo.

23. 1 Saeb; 2 Saeb; 3 Saeb; 4 Ball; 5 Ball; 6 Ball; 7 Simmons; 8 Simmons.